



Πανεπιστήμιο Πειραιώς
ΕΚΕΦΕ “ΔΗΜΟΚΡΙΤΟΣ”
Δ.Π.Μ.Σ. στην Τεχνητή Νοημοσύνη
Τμήμα Ψηφιακών Συστημάτων Πανεπιστημίου Πειραιώς
Ινστιτούτο Πληροφορικής και Τηλεπικοινωνιών ΕΚΕΦΕ
«Δημόκριτος»

**Ανάλυση Ιατρικών Εικόνων με χρήση τεχνικών Μηχανικής Μάθησης
και Βαθιών Νευρωνικών Δικτύων**

Εργασία στο μάθημα “Μηχανική Μάθηση σε Πολυμεσικά Δεδομένα”

Νικόλαος Π. Μακρής

Διδάσκοντες:

Μαγκλογιάννης Ηλίας, Καθηγητής στο Τμήμα Ψηφιακών Συστημάτων το Πανεπιστημίου Πειραιώς
Γιαννακόπουλος Θεόδωρος, Μεταδιδακτορικός Ερευνητής ΕΚΕΦΕ Δημόκριτος

Αθήνα, 2023

Εισαγωγικά Στοιχεία

- ✓ Dataset → Μαστογραφίες (800 εικόνες) → 3 κλάσεις: i. normal
 - ii. benign
 - iii. Malignant
- ✓ Στόχοι: i. Classification μαστογραφίας σε μία από τις ανωτέρω κλάσεις
 - ii. Segmentation όγκου ανεξαρτήτως κατηγορίας (benign ή malignant)
- ✓ Χρήση παραδοσιακών μεθόδων Μηχανικής Μάθησης και Βαθιάς Μάθησης για νάθε έναν από τους παραπάνω στόχους
- ✓ Απαίτηση για feature extraction για τις μεθόδους Μηχανικής Μάθησης
 - Features ανά εικόνα για Image Classification
 - Features ανά pixel νάθε εικόνας για Image Segmentation → Αυξημένο υπολογιστικό κόστος
- ✓ Μικρός αριθμός εικόνων ➔ αδυναμία εκπαίδευσης νευρωνικού δικτύου ➔ transfer learning

Machine Learning Classification (1/2)

- ✓ Grayscale εικόνες ➔ resize σε μέγεθος (256, 256)
 - ✓ 80% training dataset – 20% test dataset ➔ k-fold cross-validation οπότε όχι validation dataset
 - ✓ Baseline accuracy 56.03%
-

Feature Extraction

- ✓ HOG (Histogram of Oriented Gradients): υπολογίζει τις ιλίσεις (αλλαγές στην ένταση των γειτονικών pixel) των pixel της εικόνας σε διαφορετικές κατευθύνσεις και ποσοτικοποιεί την κατανομή αυτών των ιλίσεων σε ένα ιστόγραμμα.
- ✓ Haralick Features: texture-based features
- ✓ GLSZM (Gray-Level Size Zone Matrix): texture-based features που ποσοτικοποιούν τη χωρική κατανομή (spatial distribution) της έντασης του γκρίζου χρώματος μιας εικόνας
- ✓ LBP (Local Binary Patterns) Features: εντοπίζει texture patterns

Συνολικός αριθμός features ανά εικόνα: 76 (εφαρμογή PCA στα HOG features: > 3000 ανά εικόνα)

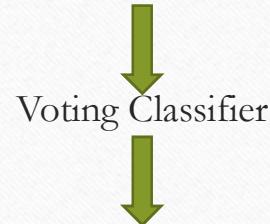
3

Machine Learning Classification (2/2)

- ✓ Δοκιμή πολλών classifiers: i. Linear SVM ii. Gaussian RBF SVM kernel iii. Polynomial SVM
iv. Random Forest v. Ada Boost

Classifier	Accuracy
Linear SVM	0.713
Gaussian RBF SVM kernel	0.67
Polynomial SVM	0.695
Random Forest	0.699
Ada Boost	0.622

- ✓ Hyperparameter Tuning → επιλέγουμε Polynomial SVM, Linear SVM και Random Forest



- ✓ Οχι ιδιαίτερα υψηλό precision
- ✓ Recall πολύ χαμηλό για την κλάση normal

Accuracy	0.7308
Precision	0.6428, 0.7212, 0.7895
Recall	0.3214, 0.9146, 0.6521
F1 score	0.4286, 0.8064, 0.7143

Baseline accuracy 56.03%



Machine Learning Segmentation (1/3)

- ✓ Resize σε μέγεθος (128, 128) (υψηλό υπολογιστικό ιόστος)
 - ✓ Εκτέλεση resize όχι μόνο στις μαστογραφίες αλλά και στις μάσκες των άγκων
 - ✓ Feature extraction ανά pixel
 - ✓ Για 800 εικόνες ➔ $128 \times 128 \times 800 = 13,107,200$ pixels
-
- ✓ Χρήση μόνο 50 εικόνων για μείωση του input των αλγορίθμων
 - ✓ Το πρόβλημα μας είναι binary classification για κάθε pixel ➔ cancerous – non-cancerous
 - ✓ Cropping εικόνων γύρω από τις καρκινικές περιοχές ➔ πρόβλημα γενίκευσης λόγω των ορίων της μαστογραφίας που συνήθως είναι σκοτεινά
 - ✓ Baseline accuracy 48.45%

Machine Learning Segmentation (2/3)

Feature Extraction

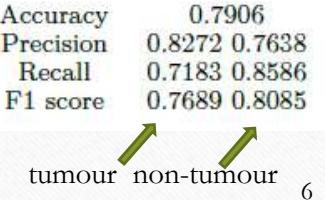
- ✓ Haralick Features
- ✓ LBP Features
- ✓ Intensity-based features (mean, skew, kurtosis, entropy κλπ.)

Συνολικός αριθμός features ανά pixel εικόνας: 22 (εξαγωγή με χρήση 5x5 mask/patch)

- ✓ Δοκιμή πολλών classifiers: i. Linear SVM ii. Polynomial SVM
iii. Random Forest iv. Ada Boost
- ✓ Δεν εκτελέσαμε Hyperparameter Tuning λόγω υψηλού υπολογιστικού κόστους
- ✓ Voting Classifier με χρήση των Polynomial SVM, Linear SVM και Random Forest

Classifier	Accuracy
Linear SVM	0.789
Polynomial SVM	0.791
Random Forest	0.798
Ada Boost	0.791

Baseline accuracy	48.45%	0.7906
Precision	0.8272	0.7638
Recall	0.7183	0.8586
F1 score	0.7689	0.8085



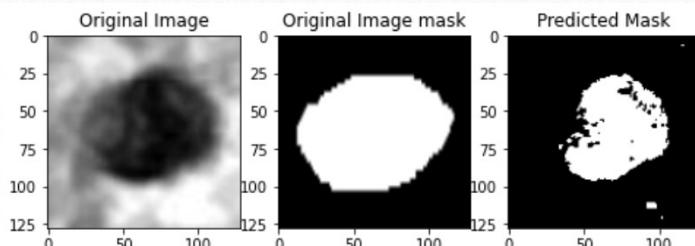
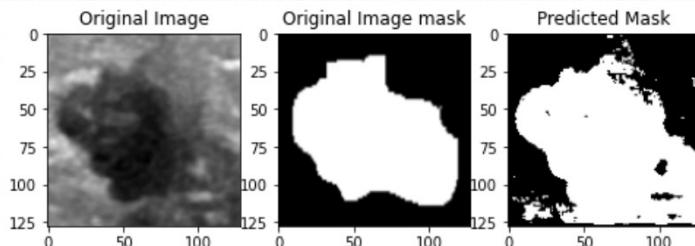
tumour non-tumour

6

Ανάλυση Ιατρικών Εικόνων με χρήση τεχνικών Μηχανικής Μάθησης και Βαθιών Νευρωνικών Δικτύων

Machine Learning Segmentation (3/3)

- ✓ Εικόνες του test set πρέπει να είναι cropped
- ✓ Χρήση του αλγορίθμου για εντοπισμό όγκου όταν ήδη γνωρίζουμε την περιοχή που εμφανίζεται



7

Ανάλυση Ιατρικών Εικόνων με χρήση τεχνικών Μηχανικής Μάθησης και Βαθιών Νευρωνικών Δικτύων

Deep Learning Classification (1/2)

- ✓ 800 εικόνες ➔ αδυναμία εκπαίδευσης νευρωνικού δικτύου ➔ transfer learning
- ✓ Χρήση του VGG19 με pre-trained βάροη του ImageNet
- ✓ Resize τις εικόνες σε (224, 224)
- ✓ Μετατροπή των grayscale εικόνων σε RGB
- ✓ Data augmentation του training set
 - a. Αρχικά 650 εικόνες για training (80% του dataset)
 - b. Τελικά περίπου 2500 εικόνες με περιστροφές των αρχικών ανά 45 μοίρες
- ✓ Παγώνουμε όλα τα layers του VGG19 εκτός από τα δύο τελευταία
- ✓ Προσθήκη ενός dense layer 50 νευρώνων με ReLU activation function για να εντοπίσουμε κάποια επιπλέον higher level features
- ✓ Προσθήκη ενός dense layer 20 νευρώνων με ReLU activation function
- ✓ Προσθήκη prediction layer

Θα μπορούσαμε να τα είχαμε αφαιρέσει.
Δεν επιβεβαιώνεται
ότι βοηθούν στο αποτέλεσμα

Deep Learning Classification(2/2)

- ✓ Σύγκριση αποτελεσμάτων με ML:

Deep Learning	Accuracy	0.796
	Precision	0.71, 0.857, 0.738
	Recall	0.815, 0.818, 0.738
	F1 score	0.759, 0.837, 0.738

Machine Learning

Machine Learning	Accuracy	0.7308
	Precision	0.6428, 0.7212, 0.7895
	Recall	0.3214, 0.9146, 0.6521
	F1 score	0.4286, 0.8064, 0.7143

-
- ✓ Γενική βελτίωση σε accuracy, Precision και Recall
 - ✓ Συνεχίζει το Precision να μην είναι το επιθυμητό. Θα θέλαμε ποσοστά άνω του 90-95%
 - ✓ Baseline accuracy 56.03%

Deep Learning Segmentation (1/2)

- ✓ Παρόμοιο data preprocessing με το Deep Learning Classification
 - ✓ Δεν πραγματοποιείται data augmentation
 - ✓ Κάνουμε resize όχι μόνο στις μαστογραφίες αλλά και στις μάσκες που μας δίνονται ως input (224, 224)
-
- ✓ Προσεγγίζουμε το πρόβλημα ως binary classification για κάθε pixel. Στόχος μας να χαρακτηρίσουμε κάθε pixel ως cancerous – non-cancerous
 - ✓ Δεν εκτελούμε κάποιου είδους cropping στις εικόνες (σε αντίθεση με το Machine Learning)

- γενίκευση του pipeline (εισάγουμε μαστογραφία και ο αλγόριθμος εντοπίζει τον όγκο)
- ✓ Χρήση εκ νέου του VGG19
 - ✓ Baseline accuracy 92.06%. Η πλειοψηφία των pixel είναι μη-καρκινικά!
 - ✓ Παράγουμε όλα τα layers του VGG19.
 - ✓ Επειδή εκτελούμε segmentation χρειαζόμαστε ένα decoder κομμάτι μετά το CNN μας. Χρήση σχεδόν αυτούσιου του decoder από το paper: "U-Net: Convolutional Networks for Biomedical Image Segmentation" by Olaf Ronneberger, Philipp Fischer, and Thomas Brox, 2015

10

Deep Learning Segmentation (2/2)

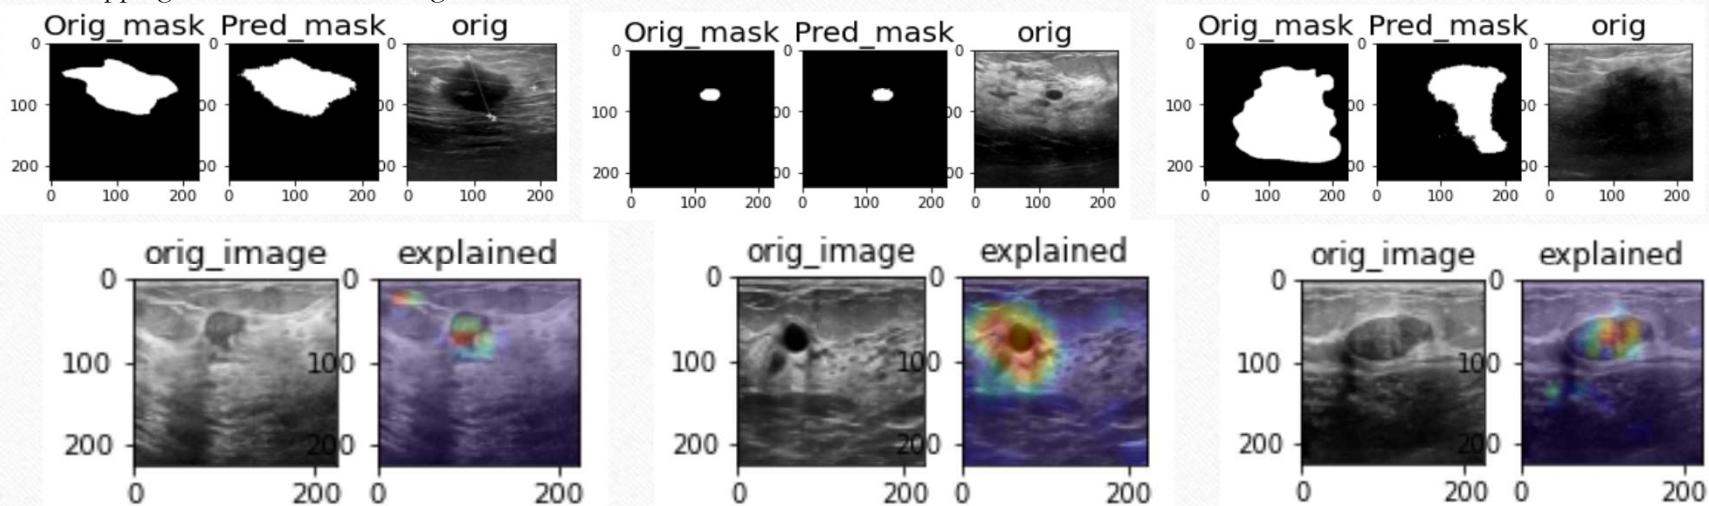
- ✓ Παρουσίαση αποτελεσμάτων DL καθώς και ML:

Deep Learning	Accuracy	0.957
	Precision	0.973 0.721
	Recall	0.98 0.651
	F1 score	0.977 0.684

Machine Learning

Accuracy	0.7906
Precision	0.8272 0.7638
Recall	0.7183 0.8586
F1 score	0.7689 0.8085

ΔΕΝ μπορεί να πραγματοποιηθεί σύγκριση των αποτελεσμάτων καθώς έχουμε διαφορετικά baselines 92.06% έναντι 48.45% εξαιτίας του cropping στο Machine Learning



11

Ανάλυση Ιατρικών Εικόνων με χρήση τεχνικών Μηχανικής Μάθησης και Βαθιών Νευρωνικών Δικτύων

Συμπεράσματα

- ✓ Οι παραδοσιακές τεχνικές μηχανικής εκμάθησης έδειξαν περιορισμούς στο segmentation των όγκων απαιτώντας cropping. Κατά συνέπεια δεν μπορούμε να δώσουμε ως input μια μαστογραφία χωρίς cropping.
- ✓ Οι Deep Learning τεχνικές φαίνεται να δουλεύουν καλά και για τα δύο task.

- ✓ Από την explainability ανάλυση, εντοπίσαμε ότι για το Deep Learning Segmentation οι περιοχές του όγκου καθώς και οι γειτονιές του διαδραματίζουν σημαντικό ρόλο στη λήψη της απόφασης.
- ✓ Απαιτείται περαιτέρω ανάλυση των Deep Learning τεχνικών διότι το precision επιθυμούμε να είναι πολύ υψηλό, γεγονός που δεν ισχύει εν προκειμένω.

Σας Ευχαριστώ πολύ

Ανάλυση Ιατρικών Εικόνων με χρήση τεχνικών Μηχανικής Μάθησης και Βαθιών Νευρωνικών Δικτύων